

data2vec과 Tensor Fusion-Mixer(TFM)을 활용한 멀티모달 감성 분석

이루안^o, 김두훈*, 김경호, 조수익, 오근철, 김주원
모두의연구소

{feelinppl, invi.dh.kim, khk172216, sik920405, gc.chris.oh, juwum13}@gmail.com

The Application of Multi-Modal Sentiment Analysis for Data2vec and Tensor Fusion-Mixer(TFM)

LouAn Lee^o, DooHoon Kim*, KyungHo Kim, Sulk Cho, GeunCheol Oh, JuWon Kim
MODULABS

“본 논문은 고용노동부 'K-디지털 플랫폼' 사업의 지원을 받아 작성하였습니다.”

요 약

본 연구는 ETRI에 공개된 KEMDy19와 KEMDy20을 활용하여 사람의 감정 상태를 예측하는 인공지능의 설계와 구현을 목적으로 한다. 이를 위해 대규모 사전학습 모델인 data2vec과 이미지, 음성, 텍스트 등의 데이터를 동시에 처리하는 것이 가능한 텐서퓨전(tensor fusion)을 도입하였다. 본 연구에서는 기존 멀티모달 방법론인 어텐션 메커니즘(attention mechanism) 또는 MLP-Mixer와 달리 Tensor Fusion-Mixer(TFM)을 제안한다. TFM은 이미지, 텍스트, 음성에 국한되었던 기존 멀티모달 모델들과는 달리 이미지가 없는 데이터셋에 대해 생체 데이터를 사용할 수 있다. 이를 통해, 본 연구에서 제안하는 모델은 KEMDy20 데이터셋에서 가중 F1-Score 0.928을 달성하였다.

1. 서 론

미디어의 발달로 다양한 콘텐츠가 생성됨에 따라 많은 양의 데이터가 생성되었고 이를 분석하는 연구도 많은 주목을 받고 있다. 이로 인해 발생하는 데이터의 형태 또한 이전의 기법으로는 분석이 어려워지고 있다. 특히, 소셜미디어, 뉴미디어와 같은 분야에서 발생하는 정보들에 대한 연구는 사용자의 성향 분석, 맞춤형 서비스라는 명목 아래 그 중요성이 더욱 부각되고 있다.

멀티모달이란 단일 모드가 아닌 텍스트, 음성, 이미지, 모션 등 다중 모드의 상호작용을 분석하는 정보과학의 한 분야이다[1]. 최근에는 다양한 분야에서 수집되는 멀티모달 데이터를 동시에 처리하고 분석하기 위하여 인공지능이 널리 활용되고 있다.

전통적인 멀티모달리티는 문학과 예술 등의 분야에서 표현의 잠재력을 의미한다[2]. 때문에 멀티모달은 표현주의 혹은 인지과학의 분야로 여겨졌다. 그러나 인공지능이 발달함에 따라 계산주의로 그 개념이 확장되었고 다양한 인공지능 모델이 멀티모달 분석에 도입되고 있다. 특히, 어텐션 메커니즘(attention mechanism)의 등장 이후 정보의 잠재영역을 효과적으로 파악할 수 있는 모델들이 제시되었으며, 트랜스포머(transformer)와 결합된 다양한 모델들이 소개되고 있다.

2. 본 론

본 연구에서는 한국전자통신연구원(ETRI)에 공개된 ETRI 한국어 감정 데이터셋을 분석하기 위해 기존에 멀티모달 방법론인 data2vec을 도입하고, 서로 다른 네가지 모드들을 융합하기 위해 TFM을 제안한다.

2.1 data2vec

data2vec은 메타(Meta)에서 발표한 트랜스포머 기반 멀티모달 자기지도 학습 프레임워크이다[3]. 음성, 텍스트, 이미지 등 각 모드를 다른 알고리즘으로 처리하던 기존의 멀티모달 감성 분석 모델과 달리, data2vec은 동일한 기법으로 서로 다른 모드를 처리하는 일반화된 멀티모달이다. 한 데이터의 모든 토큰을 학습하는 교사 모델과 블록 와이즈 마스킹(Block-wise-masking)을 학습하는 학생 모델이 Smooth L1 loss 함수를 통해 학습되는 기울기를 공유한다. 이때 data2vec은 Student model의 블록 와이즈 마스킹을 데이터의 특성에 맞춰 다르게 취해주는 전략을 통해, 동일한 알고리즘으로 서로 다른 모드들을 처리한다.

이 과정을 통해 출력되는 행렬에서 시계열 정보는 사라지고 정교한 문맥 정보만 남게 된다. 위와 같은 방식을 통해 data2vec은 감성분석 분야에서 state-of-the-art 혹은 그에

* 교신저자




그림 1. 모델 아키텍처

준하는 정도로 정확도를 향상시켰다. 본 연구의 실험에서는 data2vec 에서 텍스트 데이터를 처리하는 data2text와 오디오 데이터를 처리하는 data2audio를 특성 추출기로 활용한다.

2.2 Tensor Fusion-Mixer(TFM)

텐서퓨전(Tensor Fusion)은 멀티모달 감성분석을 위해 제시된 행렬 합성 방법이다[4]. 각 모드에 해당하는 데이터를 임베딩 후 크로네커 곱(kronecker product)을 통해 하나의 3차원 행렬로 융합한다. 텐서퓨전은 이처럼 크로네커 곱을 활용하여 외적 혹은 내적 등 다른 행렬 연산에 비해 각 모드 간 연관성을 더 넓은 범위로 확대할 수 있다. 또한, 어텐션 계열의 메커니즘, 트랜스포머 기반 모델들과 달리 모드를 융합함에 있어 추가적인 파라미터를 발생시키지 않는다.

본 연구의 실험에서는 텍스트와 음성 데이터의 특성을 data2vec으로 추출하고, 1차원 컨볼루션 레이어를 통해 피부 온도와 생체-전기 신호데이터의 특성을 추출한다. 그림 1과 같이 텍스트와 오디오, 각각의 1차원 특성행렬 (Z^T, Z^W)과 체온, EDA의 특성행렬(Z^{TS})은 크로네커 곱을 사용하여 텐서퓨전으로 융합된다. 이 3차원 텐서($Z^T \otimes Z^W \otimes Z^{TS}$)를 컨볼루션 레이어에 통과시켜 수용 영역(receptive field)의 특성을 분석하고 MLP(Multi-Layer Perceptron)에 연결시켜 최종 출력 값을 분류한다. 이러한 전 과정을 Tensor Fusion-Mixer(TFM)이라 한다.

3. 실험

3.1 데이터

실험 데이터셋은 한국전자통신연구원(ETRI)에 공개된 ETRI 한국어 감정 데이터셋을 사용하였다. 한국어 감정 데이터셋 (KEMDy19, KEMDy20)에는 발화자가 두 명 이상인 대화에서 기록된 음성, 발화 텍스트, 생체 데이터를 포함한다. 또한, 10명의 평가자가 발화자의 감정을 기쁨, 놀람, 분노, 중립, 혐오, 공포, 슬픔 총 7개의 항목으로 분류한 라벨이 포함되어 있다. 생체 데이터는 피부 온도, 생체-

전기 전도도(Electrodermal Activity, EDA), 심장 박동 간격을 측정된 데이터이다. 이 중 심장 박동 간격을 측정된 데이터는 다수의 결측치가 확인됨에 따라 실험에서 제외되었고 피부 온도, EDA를 생체 데이터로 사용하였다.

KEMDy20에는 그림 2의 (b)와 같이 중립 라벨이 전체 데이터셋의 90% 이상을 점유하는 데이터 불균형이 존재한다. 이를 해결하기 위해 KEMDy19, KEMDy20 두 데이터셋을 통합하고 중립 라벨에 해당하는 데이터 중 일부를 제거하는 다운 샘플링을 통해 그림 2의 (c)와 같이 분포를 변경하는 전처리를 수행하였다.

KEMDy19, KEMDy20는 각각 20개와 40개의 세션으로 구성되어 있다. 이 중 KEMDy20에 12, 17에 해당하는 세션에는 피부 온도 및 EDA 데이터가 존재하지 않기 때문에 데이터셋에서 제외하였다. 따라서 전체 58개 세션 중 42개의 세션을 학습 데이터, 8개의 세션을 시험 데이터, 나머지 8개의 세션을 검증 데이터로 구분하였다.




그림 2. KEMDy19, KEMDy20와 전처리 이후 데이터의 분포

3.2 실험 방법

실험에서 텍스트 파일은 KoBERT로 사전 학습된 data2vec을 통해 특성이 추출되었다. data2vec을 통과한 1차원 특성행렬이 임베딩 차원으로 사용되었다. 음성 데이터에 해당하는 wav 파일은 960여 시간의 오디오 데이터를 사전 학습시킨 'data2vec-audio-large-960' 모델을 사용하여 특성을 추출하였다. 텍스트 데이터와 마찬가지로 data2vec에서

추출된 1차원 특성 행렬을 임베딩 차원으로 사용하였다.

시계열 데이터인 피부 온도와 EDA는 시계열적 패턴을 파악하기 위해 컨볼루션 레이어를 사용하여 임베딩하였다. 1차원의 피부 온도와 EDA 데이터를 컨볼루션 레이어에 통과시킨 후 결합(concat)하고, 다시 컨볼루션 레이어를 통해 임베딩하였다. 이후, 본문에서 언급한 바와 같이 TFM을 통해 데이터를 융합시키고 감정에 대한 예측 값을 출력한다.

실험에 사용되는 KEMDy19, KEMDy20 데이터셋에는 복수의 감정 상태 라벨을 갖는 데이터도 존재한다. 이에 따라 모델은 모든 라벨을 단일 감정상태로 사상(mapping)하여 예측하였다. 옵티마이저(optimizer)는 Adam을 사용하였다. 모델의 Loss Function은 데이터가 불균형하게 분포할 때 주로 사용되는 가중 MSE(Weighted Mean Square Error)를 사용하였다. 모델의 평가 지표인 정확도는 가중 F1-Score를 사용하였다.

3.3 결과

실험의 결과는 표 1과 같다. 검증 데이터셋에 해당하는 8개의 세션으로 평가하였을 때 85.6%의 정확도, 0.928의 가중 F1-Score를 기록했다. 이는 ETRI의 한국어 감정 데이터셋에 국한하여 이른바 state-of-the-art 수준으로 평가할 수 있다.

표 1. 실험 결과의 평가 지표별 성능

Metric	Accuracy(%)	Weighted F1-Score	Weighted recall	Weighted precision
Result	85.609	0.928	0.865	1.0

3.4 결과 분석

본 실험에 사용된 오디오와 텍스트 데이터는 모두 data2vec을 통해 임베딩 되었으며, 시계열 데이터 또한 앞서 언급한 컨볼루션 필터를 통해 임베딩하였다. 실험을 통해 텍스트 및 오디오 데이터와 시계열 데이터를 TFM으로 학습시켰을 때 높은 수준의 성능을 확인할 수 있었다. 표 2는 이전 KEMDy 데이터셋 분석을 수행한 MLP-Mixer 기반 모델[5]과 본 연구의 실험과 같이 data2vec으로 임베딩 한 데이터들을 TFM이 아닌 Multi-Layer Perceptron(MLP)로 학습된 모델과 본 연구의 TFM으로 학습된 모델을 비교한 결과이다. TFM 모델의 경우 시계열 데이터인 생체 데이터를 제외한 모델과 포함한 모델로 경우를 나누어 그 성능을 비교하였다.

표 2. 각 모델간 성능비교

Model	Accuracy(%)	Weighted F1-Score
Multi-modal MLP-Mixer[5]	78.9	0.784
data2vec with MLP	71.7	0.762
data2vec with TFM (without time-series data)	75.9	0.765
data2vec with TFM	85.6	0.928

데이터를 MLP로 학습시킨 모델의 경우 정확도 71.7%, 가중 F1-Score 0.762를 기록하였다. 한편, 시계열 데이터인 생체 데이터를 제외한 TFM 모델의 경우 MLP 모델에 비해 미세한 성능향상을 보였지만 유의미한 변화는 확인하지 못하였다. 본 연구에서 제시한 TFM을 도입하고 생체 데이터를 사용한 경우 85.6%의 정확도와 0.928의 가중 F1-Score를 나타내며 두 성능 지표에서 우수한 결과를 기록했다.

4. 결 론

실험을 통해 멀티모달 감성분석에 일반적으로 사용하는 이미지, 음성, 텍스트 등의 정보 뿐만 아니라 체온, 생체-전기 전도도 등 신체의 미세한 변화에 대한 데이터 역시 감성 분석에 큰 영향을 미친다는 점을 확인하였다. 또한, TFM을 통해 감성 분석에 있어 시계열 생체 데이터의 효과를 극대화하여 유용하게 활용할 수 있다는 사실을 실험을 통해 입증하였다.

실험에서 사용한 data2vec중 음성데이터의 특성 추출기로 사용한 data2vec은 영어 발화자의 데이터를 사전학습한 모델이다. 이를 한국어 발화자의 데이터로 fine-tuning하여 특성 추출기로 활용한다면 더 우수한 성능을 보일 것으로 기대된다.

참 고 문 헌

- [1] S Poria, E Cambria, R Bajpai, A Hussain. "A review of affective computing: From unimodal analysis to multimodal fusion", Information Fusion, Volume 37, pp. 98-125, Sep, 2017.
- [2] GR Kress, Multimodality: A social semiotic approach to contemporary communication, Routledge, pp. 54-59, 2010.
- [3] Alexei Baevski, Wei-Ning Hsu et, at, "data2vec: A General Framework for Self-supervised Learning in Speech, Vision and Language", PMLR, 162, pp. 1298-1312, Feb, 2022.
- [4] Amir Zadeh, Minghai Chen et, at, "Tensor Fusion Network for Multimodal Sentiment Analysis", EMNLP, pp. 1103-1114, Jul, 2017.
- [5] 방나모, 연희연, 이지현 외 1명, "MLP-Mixer 구조를 활용한 대화에서의 멀티모달 감정 인식", 한국정보과학회 학술발표 논문집, pp. 2288-2290, Jun, 2022.